

S4

Emmanuelle Saillard emmanuelle.saillard@inria.fr

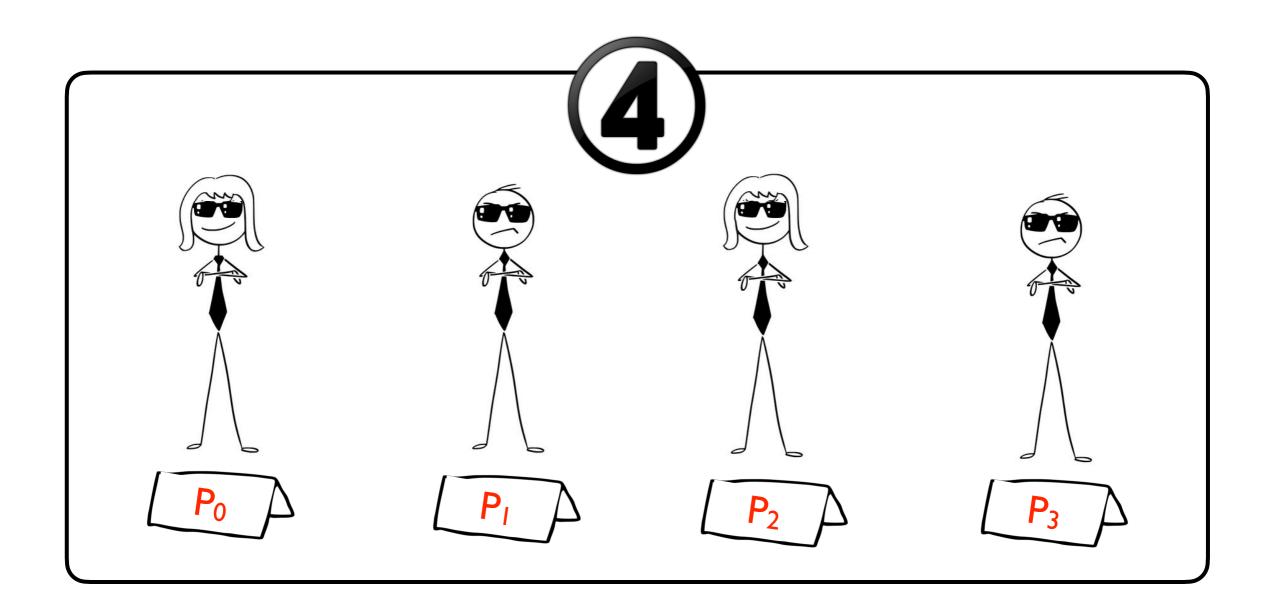
Langages du parallélisme

- 1. Manipulation de structures MPI
 - 1. Communicateurs
 - 2. Opérateurs définis par l'utilisateur
- 2. Topologie MPI
- 3. Types dérivés

- 1. Manipulation de structures MPI
 - 1. Communicateurs
 - 2. Opérateurs définis par l'utilisateur
- 2. Topologie MPI
- 3. Types dérivés

- 1. Manipulation de structures MPI
 - 1. Communicateurs
 - 2. Opérateurs définis par l'utilisateur
- 2. Topologie MPI
- 3. Types dérivés

Un concept de base: Communicateur



Communicateur = groupe de processus + contexte de communication

- → Prédéfini: MPI COMM WORLD avec tous les processus
- → Type: MPI Comm

Communicateurs et groupes

Petit nombre de processus

→ MPI_COMM_WORLD suffisant

Grand nombre de processus

- → MPI_COMM_WORLD pas toujours pratique, on veut pouvoir:
 - faire des communications entre un sous ensemble de processus
 - travailler sur des jeux de données différents

Deux notions

- 1. Groupe: ensemble ordonné de processus
- 2. Communicateur: groupe mais qui spécifie un domaine de communication

Communicateurs

Communicateur = groupe de processus + contexte de communication (canal entre des processus pour échanger des messages)

Les opérations pour

- -créer les communicateurs sont des collectives
- -accéder à une information d'un communicateur sont locales

Deux types de communicateurs existent:

- -Intracommunicateur : communication dans un groupe
- -Intercommunicateur : communication entre deux groupes

Créer des communicateurs

Duplication, split et comparaison

Créer des communicateurs

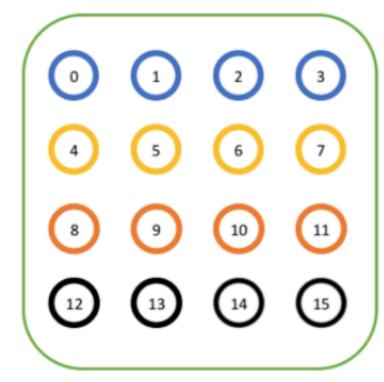
int MPI_Comm_split(MPI_Comm comm, int color, int key, MPI_Comm *newcomm)

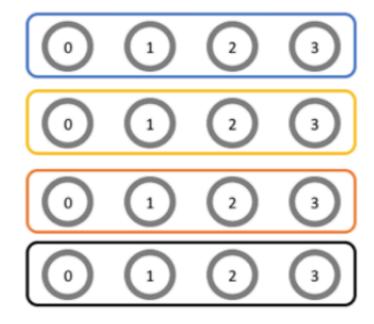
determine à quel communicateur le processus va appartenir

determine l'ordre (rank)

au sein de chaque

nouveau communicateur

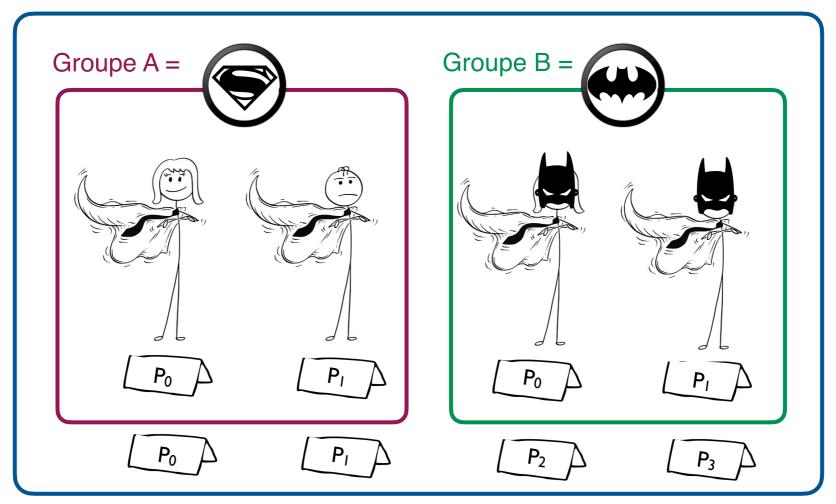




Groupes

Autres moyens de créer des communicateurs de manière **plus flexible** via des **groupes**

Groupe = ensemble de processus ordonnés



Groupe de base, associé à MPI_COMM_WORLD

Créer des groupes

Un constructeur à partir du communicateur:

```
-MPI_Comm_group (MPI_Comm comm, MPI_Group *group)
-MPI_Group_size (MPI_Group group, int *size)
-MPI_Group_rank (MPI_Group group, int *rank)
```

→ retourne le rang du processus dans le groupe ou MPI_UNDEFINED

Correspondance entre les rangs des processus du group1 et leur rang dans group2

```
MPI_Group_translate_ranks(group1, n, rank1, group2, rank2)
```

Comparer deux groupes MPI_Group_compare (group1, group2, result). Le résultat est

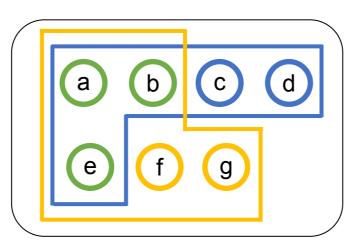
- MPI_IDENT si les éléments des groupes sont les mêmes ainsi les rangs ;
- MPI_SIMILAR si les éléments des groupes sont les mêmes mais avec des rangs différents;
- MPI_UNEQUAL sinon

Supprimer un groupe : MPI_Group_free (group)

Créer des groupes

- -Où * ∈ {union, intersection, difference}
- -newgroup contient les processus satisfaisants l'opération * d'abord ordonnés selon l'ordre dans le groupe 1 et ensuite en fonction de l'ordre dans le groupe 2.
- -Dans le nouveau groupe chaque processus sera présent seulement 1 fois.

Exemple



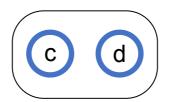
Union

-newgroup = $\{a, b, c, d, e, f, g\}$



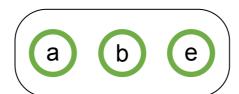
Différence

-newgroup = $\{c, d\}$



Intersection

-newgroup = $\{a, b, e\}$



Intracommunicateurs

Qu'est ce qu'un intracommunicateur?

- Des processus
- Un groupe
- Un contexte de communication
- Une topologie (optionnel)

Creation à partir d'un ancien communicateur et d'un groupe

Prototypes:

- int MPI_Comm_create(MPI_Comm comm, MPI_Group group, MPI Comm *newcomm)
- int MPI_Comm_create_group(MPI_Comm comm, MPI_Group group, int tag, MPI_Comm *newcomm)

Intracommunicateurs

int MPI_Comm_create(MPI_Comm comm, MPI_Group group,

MPI_Comm *newcomm)

Doit être appelée par tous
les processus dans le
groupe associé à comm

int MPI_Comm_create_group(MPI_Comm comm, MPI_Group group, int tag,

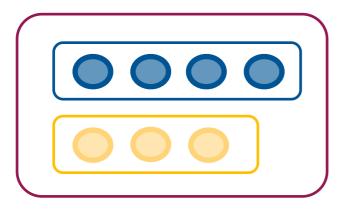
MPI_Comm *newcomm)

Doit être appelée par tous
les processus dans le
groupe group

Sous ensemble du groupe
associé à comm
groupe group

Intercommunicateurs

Qu'est-ce qu'un intercommunicateur?



- Plus de processus
- **Deux** groupes
- Un communicateur

Objet qui construit un domaine de communication entre deux groupes disjoints de processus.

Autorise des communications entre les groupes: très utile pour les couplages de codes, les simulations client/serveur

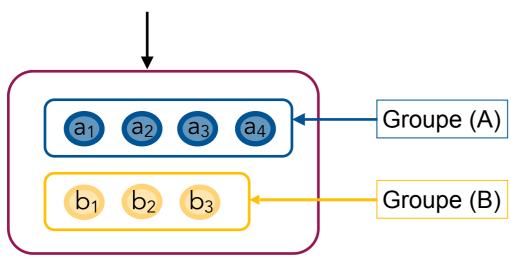
Prototype

```
int MPI_Intercomm_create(MPI_Comm local_comm, int local_leader,
MPI_Comm peer_comm, int remote_leader, int tag, MPI_Comm *newintercomm)
```

Intercommunicateurs

Objet qui construit un domaine de communication entre deux groupes disjoints de processus

Intercommunicateur



NB: Il est IMPOSSIBLE d'envoyer un message à un processus dans le même groupe en utilisant ce communicateur.

Pour tous les processus de (A)

- (A) est le groupe local;
- (B) est le groupe remote

Pour tous les processus de (B)

- (A) est le groupe remote ;
- (B) est le groupe local.

Groupes et communicateurs spéciaux

Groupes spéciaux :

Groupe sans aucun processus: MPI_GROUP_EMPTY

MPI_GROUP_NULL signifie que l'objet groupe n'existe pas.

Communicateurs spéciaux:

Communicateur initial: MPI_COMM_WORLD

Communicateur qui contient le processus d'appel: MPI_COMM_SELF (utile pour les I/O)

MPI_COMM_NULL signifie que le communicateur n'existe pas

- 1. Manipulation de structures MPI
 - 1. Communicateurs
 - 2. Opérateurs définis par l'utilisateur
- 2. Topologie MPI
- 3. Types dérivés

Opérations définies par l'utilisateur

```
int MPI_Op_create (

MPI_User_function *user_fn(in),

int commute(in),

Pointeur de fonction user_fn

MPI_Op *op(out),

Prototype:
    void (*f) (void* invec, void* inoutvec, int *len, MPI_Datatype *datatype);
```

Opérations définies par l'utilisateur

```
int MPI_Op_create (

MPI_User_function *user_fn(in),

int commute(in),

MPI_Op *op(out),

);

Vaut 1 si l'opération est commutative
```

Opérations définies par l'utilisateur

Exemple

Creation de l'opération

```
MPI_Op_create( (MPI_User_function *)user_add, 1, &op );
```

Libération de l'opération

```
MPI_Op_free(&op);
```

- 1. Manipulation de structures MPI
 - 1. Communicateurs
 - 2. Opérateurs définis par l'utilisateur
- 2. Topologie MPI
- 3. Types dérivés

Dans les méthodes de partitionnement de domaine sur des structures régulières où l'on fait correspondre le domaine de calcul à la grille de processus, il est intéressant de pouvoir disposer les processus suivant une topologie régulière

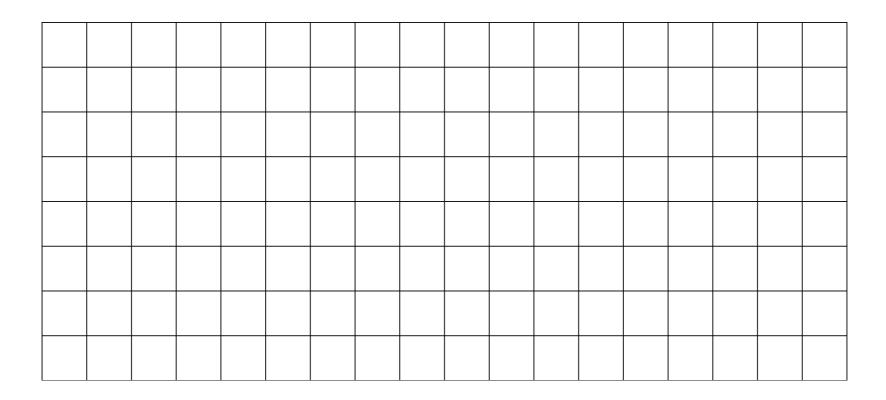
MPI permet de définir des topologies virtuelles de type :

-Cartésien :

- → chaque processus est défini dans une grille de processus ;
- → la grille peut être périodique ou non ;
- → les processus sont identifiés par leurs coordonnées dans la grille
- -Graphe : Généralisation à des topologies plus complexes

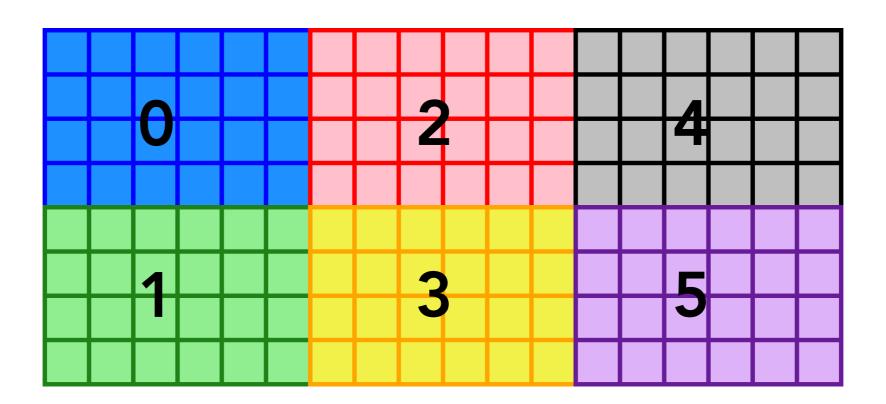
Considérons une grille multi-dimensionnelle: exemple 2D

→ Décomposition en 6 rangs



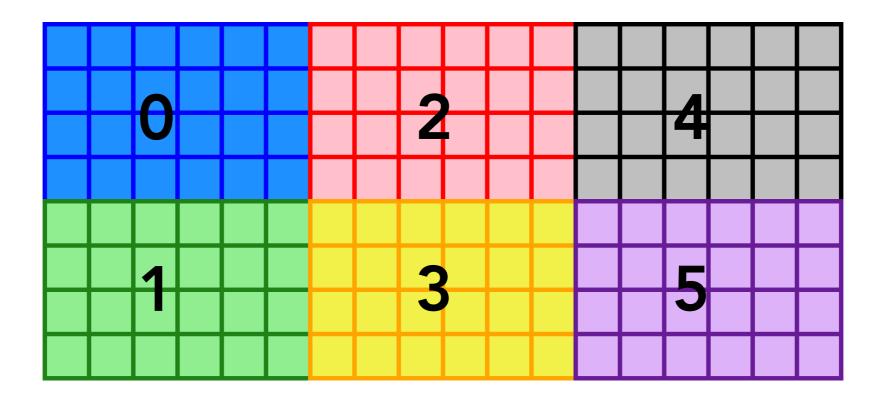
Considérons une grille multi-dimensionnelle: exemple 2D

- → Décomposition en 6 rangs
- \rightarrow 6x4 = 24 cellules par rang MPI



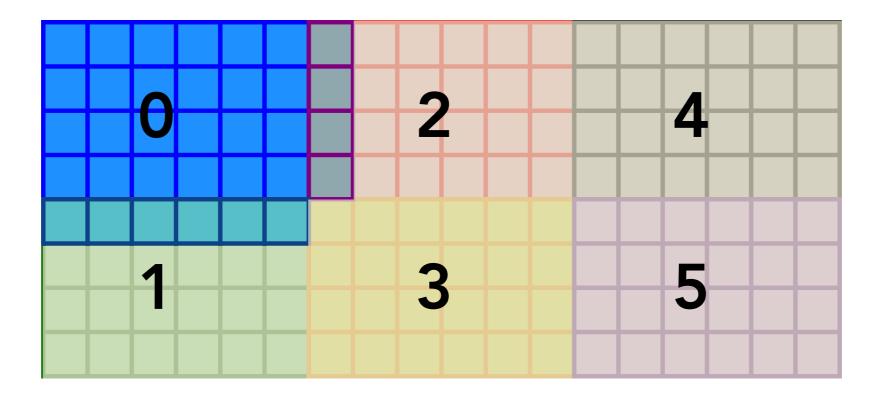
Considérons une grille multi-dimensionnelle: exemple 2D

→ La mise à jour d'une cellule requiert la contribution de ses voisins directs



Considérons une grille multi-dimensionnelle: exemple 2D

→ La mise à jour d'une cellule requiert la contribution de ses voisins directs



Topologie cartésienne

```
MPI Cart create (MPI Comm comm old, int ndims, const int dims[],
const int periods[], int reorder, MPI Comm *comm cart);
         comm old
  → IN
                     (communicator)
         ndims
  → IN
                     (nombre de dimensions de la grille)
         dims
  → IN
                     (tableau des dimensions de la grille)
         periods
                     (tableau spécifiant la périodicité)
  → IN
  → IN
         reorder
                     (si true, renumérotation des processus)
  → OUT comm_cart
                     (communicateur avec la topologie cartésienne)
```

Si reorder = false, le rang des processus est le même dans comm et dans comm_cart

Fonctions associées à la grille

• MPI_Cart_rank retourne le rang du processus associé aux coordonnées dans la grille ;

```
MPI_Cart_rank(comm_cart, coords, rang)
```

MPI_Cart_coords renvoie les coordonnées d'un processus de rang donné;

```
MPI_Cart_coords(comm_cart, rank, dim, coords)
```

• MPI_Cart_shift donne le processeur avant et après dans la direction d

```
MPI_Cart_shift(comm_cart, d, pas, rang_precedent, rang_suivant)
```

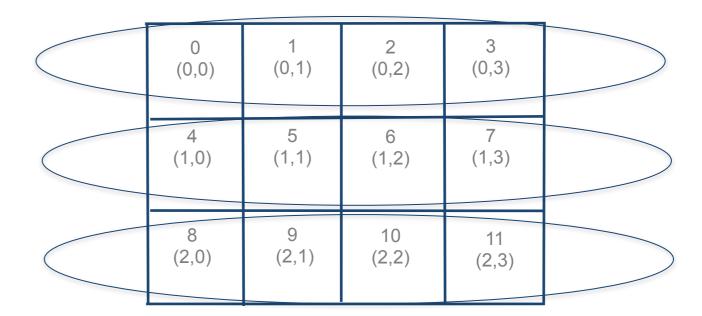
pas : longueur du shift - et +

d: direction du shift

Si on sort de la topologie, MPI_PROC_NULL est retourné

Exemple

```
dims[0] = 3;
dims[1] = 4;
periods[0] = 0;
periods[1] = 1;
reorder = 1;
```



MPI_Cart_create(MPI_COMM_WORLD,2,dims,periods,reorder,&grid_2D);

```
MPI_Cart_coords(grid_2D, rank, 2, coords);
MPI_Cart_rank( grid_2D, coords, &rank2d );
MPI_Cart_shift(grid_2D, 0, 1, &dessous, &dessus);
MPI_Cart_shift(grid_2D, 1, 1, &avant, &apres);
```

Exemple

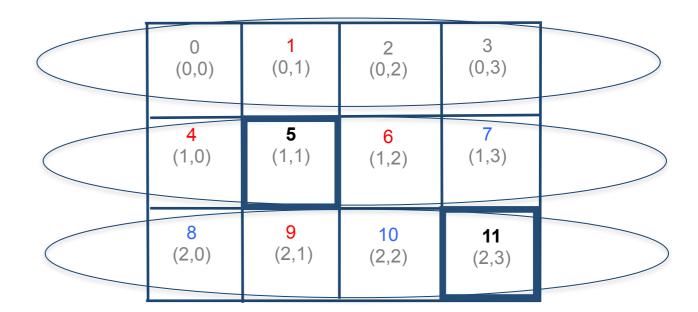
Rang 5

Coordonnées (1,1).

Mes voisins:

avant 4 et après 6

dessus 1 dessous 9



Rang 11

Coordonnées (2,3).

Mes voisins:

avant 10 et après 8

dessus 7 dessous -2

Dans cette implémentation MPI_PROC_NULL = -2

Partitionnement cartésien

Souvent on souhaite exécuter une opération sur une partie de la topologie :

- -les lignes/colonnes (si grille 2D), les plans (si grille 3D)
- -Un communicateur par ligne/colonne/plan (autant de communicateurs que de plans)
- -Des opérations collectives seulement sur le nouveau communicateur

MPI Cart sub(comm, remain dims, subcom)

```
IN comm communicateur cartésien
IN remain_dims tableaux précisant les dimensions de la grille que l'on garde
```

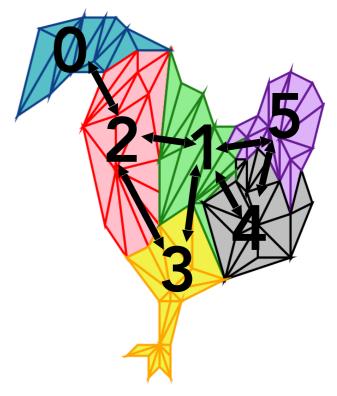
OUT subcomm communicateur avec la topologie cartésienne

Graphe de processus

Dans beaucoup d'applications, la décomposition d'un domaine n'est pas cartésienne mais sous forme d'un graphe.

Un rang a besoin d'échanger des données avec ses voisins

```
0 <-> 2
2 <-> 1; 2 <-> 3
1 <-> 3; 1 <-> 4; 1 <-> 5
4 <-> 5;
```



Graphe de processus

Dans beaucoup d'applications, la décomposition d'un domaine n'est pas cartésienne mais sous forme d'un graphe.

MPI_Graph_create permet de définir une topologie de type graphe

```
MPI Graph create (comm, Nbnodes, index, edges, reorder, comm graph)
       comm communicateur
TN
TN
      Nbnodes
                 nombre de nœuds dans le graphe
                 décrit le degré des nœuds
ΙN
      index
TN
       edges
                 décrit les arêtes associées au nœud
                 true on réordonne les processus ;
TN
       reorder
                    false on garde l'ordre de comm
OUT comm graph
                  communicateur avec la topologie graphe
```

Graphe de processus

Deux autres fonctions sont utiles pour connaître

-Le nombre de voisins, nneighbors, pour un processus donné

```
int MPI_Graph_neighbors_count( MPI_Comm comm, int rank,
int *nneighbors )
```

-La liste des voisins pour un processus donné

```
int MPI_Graph_neighbors( MPI_Comm comm, int rank,
int maxneighbors, int *neighbors)
```

maxneighbors : taille du tableau neighbors

comm : intracommunicateur avec une topologie de graphe.

Message Passing Interface

- 1. Manipulation de structures MPI
 - 1. Communicateurs
 - 2. Opérateurs définis par l'utilisateur
- 2. Topologie MPI
- 3. Types dérivés

Types prédéfinis

MPI_Datatype	C datatype	Fortran datatype
MPI_CHAR	signed char	CHARACTER
MPI_SHORT	signed short int	INTEGER(2)
MPI_INT	signed int	INTEGER
MPI_LONG	signed long int	
MPI_UNSIGNED_CHAR	unsigned char	
MPI_UNSIGNED_SHORT	unsigned short	
MPI_UNSIGNED	unsigned int	
MPI_UNSIGNED_LONG	unsigned long int	
MPI_FLOAT	float	REAL(4)
MPI_DOUBLE	double	REAL(8)
MPI_LONG_DOUBLE	long double	DOUBLE PRECISION*8

Types dérivés

Pour quoi faire?

Pour le moment, on sait envoyer et recevoir des données qui ont le même type et qui sont contiguës en mémoire.

La construction de types dérivés dans MPI permet d'envoyer et recevoir une partie d'un tableau, une structure, ...

Types contigus

MPI_Type_contiguous(int count, MPI_Datatype oldtype, MPI_Datatype
*newtype)

```
IN count nombre d'éléments (entier positif)
IN oldtype ancien type (MPI_Datatype handle)
OUT newtype nouveau type (MPI Datatype handle)
```

MPI_Type_contiguous crée un nouveau type à partir d'un ensemble homogène de types prédéfinis de données contiguës en mémoire

```
MPI_Type_contiguous( 3, MPI_Float, &newtype )
```

Manipulation

MPI impose que tous les types de données utilisées pour les communications et les opérations sur les fichiers doivent être enregistrés

→ Permet d'optimiser la représentation des types

```
int MPI_Type_commit( MPI_Datatype* )
int MPI_Type_free( MPI_Datatype* )
```

```
/* create a type which describes a line of ghost cells */
/* buf[1..nxl] set to ghost cells */
int nxl;
MPI_Datatype ghosts;

MPI_Type_contiguous (nxl, MPI_DOUBLE, &ghosts);
MPI_Type_commit(&ghosts);
MPI_Send (buf, 1, ghosts, dest, tag, MPI_COMM_WORLD);
...
MPI_Type_free(&ghosts);
```

Types à pas constants - vecteurs

```
MPI_Type_vector (int count, int blocklength, int stride,
MPI_Datatype oldtype, MPI_Datatype *newtype);
```

```
IN count nombre de blocs (entier positif)
IN blocklength nombre d'éléments dans chaque bloc
IN stride nombre d'éléments entre le début de chaque bloc
IN oldtype ancien type (MPI_Datatype handle)
OUT newtype nouveau type (MPI Datatype handle)
```

MPI_Type_vector crée un nouveau type basé sur la réplication d'un type de données constitué de blocs régulièrement espacés

```
MPI_Datatype mytype;
MPI_Type_vector_(3, 4, 5, MPI_DOUBLE, &mytype);
MPI_Type_commit(&mytype);
```

```
MPI_Datatype mytype;
MPI_Type_vector_(3, 4, 5, MPI_DOUBLE, &mytype);
MPI_Type_commit(&mytype);
```

oldtype = MPI_DOUBLE

```
MPI_Datatype mytype;
MPI_Type_vector_(3, 4, 5, MPI_DOUBLE, &mytype);
MPI_Type_commit(&mytype);
```

- oldtype = MPI_DOUBLE
- blocklength = 4

```
MPI_Datatype mytype;
MPI_Type_vector_(3, 4, 5, MPI_DOUBLE, &mytype);
MPI_Type_commit(&mytype);

• oldtype = MPI_DOUBLE

• blocklength = 4

• count = 3
```

```
MPI_Datatype mytype;
MPI_Type_vector_(3, 4, 5, MPI_DOUBLE, &mytype);
MPI_Type_commit(&mytype);

• oldtype = MPI_DOUBLE ____
• blocklength = 4 ______
• count = 3 ______
• stride = 5 ______
```

```
MPI_Datatype mytype;
MPI_Type_vector_(3, 4, 5, MPI_DOUBLE, &mytype);
MPI_Type_commit(&mytype);

• oldtype = MPI_DOUBLE _____
• blocklength = 4 ______
• count = 3 _______
• stride = 5 ______
• mytype:
```

Types à pas constants - vecteurs

MPI_Type_hvector (int count, int blocklength, MPI_Aint stride,
MPI_Datatype oldtype, MPI_Datatype *newtype);

```
IN count nombre de blocs (entier positif)
IN blocklength nombre d'éléments dans chaque bloc
IN stride nombre d'octets entre le début de chaque bloc
IN oldtype ancien type (MPI_Datatype handle)
OUT newtype nouveau type (MPI Datatype handle)
```

- → Même chose que MPI_Type_vector sauf que stride est donné en octets
- « h » pour heterogeneous

Types homogène à pas variable

```
MPI_Type_indexed (int count, int *array_of_blocklengths, int
*array_of_displacements, MPI_Datatype oldtype, MPI_Datatype
*newtype)
```

Réplication d'un type de données en une suite de blocs.

Chaque bloc peut

- -Contenir un nombre différent d'éléments ;
- -Avoir un espacement différent.

```
int blocklength[3] = {2,3,1}
int displacement[3] = {0,3,8}
MPI_Datatype mytype;
MPI_Type_vector_(3, &blocklength, &displacement, MPI_DOUBLE_2, &mytype);
MPI_Type_commit(&mytype);

• oldtype = MPI_DOUBLE_2  
• blocklength = 2,3,1  
• stride = 0,
```

```
int blocklength[3] = {2,3,1}
int displacement[3] = {0,3,8}

MPI_Datatype mytype;
MPI_Type_vector_(3, &blocklength, &displacement, MPI_DOUBLE_2, &mytype);
MPI_Type_commit(&mytype);

• oldtype = MPI_DOUBLE_2
• blocklength = 2,3,1
• stride = 0,3
```

```
int blocklength[3] = {2,3,1}
int displacement[3] = {0,3,8}

MPI_Datatype mytype;
MPI_Type_vector_(3, &blocklength, &displacement, MPI_DOUBLE_2, &mytype);
MPI_Type_commit(&mytype);

• oldtype = MPI_DOUBLE_2
• blocklength = 2,3,1
• stride = 0,3,8
```

```
int blocklength[3] = \{2,3,1\}
int displacement[3] = \{0,3,8\}
MPI_Datatype mytype;
MPI_Type_vector_(3, &blocklength, &displacement, MPI_DOUBLE_2,
&mytype);
MPI_Type_commit(&mytype);

    oldtype = MPI_DOUBLE_2

blocklength = 2,3,1
• stride = 0,3,8
mytype:
```

```
int blocklength[3] = \{2,3,1\}
int displacement[3] = \{0,3,8\}
MPI_Datatype mytype;
MPI_Type_vector_(3, &blocklength, &displacement, MPI_DOUBLE_2,
&mytype);
MPI_Type_commit(&mytype);
oldtype = MPI_DOUBLE_2
blocklength = 2,3,1
• stride = 0,3,8
 mytype:
```

```
int blocklength[3] = \{2,3,1\}
int displacement[3] = \{0,3,8\}
MPI_Datatype mytype;
MPI_Type_vector_(3, &blocklength, &displacement, MPI_DOUBLE_2,
&mytype);
MPI_Type_commit(&mytype);
oldtype = MPI_DOUBLE_2
blocklength = 2,3,1
• stride = 0,3,8
mytype:
```

```
int blocklength[3] = \{2,3,1\}
int displacement[3] = \{0,3,8\}
MPI_Datatype mytype;
MPI_Type_vector_(3, &blocklength, &displacement, MPI_DOUBLE_2,
&mytype);
MPI_Type_commit(&mytype);
oldtype = MPI_DOUBLE_2
blocklength = 2,3,1
• stride = 0,3,8
mytype:
```

```
int blocklength[3] = \{2,3,1\}
int displacement[3] = \{0,3,8\}
MPI_Datatype mytype;
MPI_Type_vector_(3, &blocklength, &displacement, MPI_DOUBLE_2,
&mytype);
MPI_Type_commit(&mytype);
oldtype = MPI_DOUBLE_2
blocklength = 2,3,1
• stride = 0,3,8
mytype:
```

Types homogène à pas variable

MPI_Type_create_hindexed (int count, int *array_of_blocklengths, int
*array_of_displacements, MPI_Datatype oldtype, MPI_Datatype
*newtype)

→ Même chose que MPI_Type_indexed sauf que a_of_d est donné en octets

Structures quelconques

```
MPI_Type_create_struct (int count, int *array_of_blocklengths,
MPI_Aint *array_of_displacements, MPI_Datatype *array_of_types,
MPI_Datatype *newtype)
```

```
IN count nombre de blocs(entier positif)

IN a_of_b nombre d'éléments dans chaque bloc (tableau d'entiers)

IN a_of_d déplacement en octets de chaque bloc (tableau d'Aint)

IN a_of_t type des éléments dans chaque bloc (tableau de MPI_Datatype)

OUT newtype nouveau type de données (MPI Datatype handle)
```

- → Constructeur de type le plus général
- → Permet à chaque bloc d'être la réplication de types différents

```
MPI_Datatype types[3] = {DOUBLE, INT, SHORT}
int blocklength[3] = {2,2,5}
MPI_Aint displacement[3] = {0,14,26}
MPI_Datatype mytype;
MPI_Type_create_struct(3, &blocklength, &displacement, &types, &mytype);
MPI_Type_commit(&mytype);
```

Rappel: 1 short = 2 octets

blocklength = 2,2,5

stride (bytes)= 0,14,26

mytype:

```
MPI_Datatype types[3] = {DOUBLE, INT, SHORT}
int blocklength[3] = \{2,2,5\}
MPI_Aint displacement[3] = {0,14,26}
MPI_Datatype mytype;
MPI_Type_create_struct(3, &blocklength, &displacement, &types, &mytype);
MPI_Type_commit(&mytype);
 oldtype = double, int, short
 blocklength = 2,2,5

    stride (bytes)= 0,14,26
```

```
MPI_Datatype types[3] = {DOUBLE, INT, SHORT}
int blocklength[3] = {2,2,5}
MPI_Aint displacement[3] = {0,14,26}
MPI_Datatype mytype;
MPI_Type_create_struct(3, &blocklength, &displacement, &types, &mytype);
MPI_Type_commit(&mytype);

• oldtype = double, int, short
• blocklength = 2,2,5
• stride (bytes)= 0,14,26
```

mytype:



stride (bytes)= 0,14,26



stride (bytes)= 0,14,26

```
MPI_Datatype types[3] = {DOUBLE, INT, SHORT}
int blocklength[3] = \{2,2,5\}
MPI_Aint displacement[3] = {0,14,26}
MPI_Datatype mytype;
MPI_Type_create_struct(3, &blocklength, &displacement, &types, &mytype);
MPI_Type_commit(&mytype);
 oldtype = double, int, short
 blocklength = 2,2,5

    stride (bytes)= 0,14,26

  mytype:
```

```
struct Partstruct{
  char class;
  double d[6];
  char b[7];
struct Partstruct particle[1000];
int dest, tag;
MP Comm comm;
MPI Datatype Particletype;
MPI Datatype type[3] = {MPI CHAR, MPI DOUBLE, MPI CHAR};
int blocklen[3] = \{1, 6, 7\};
MPI Aint disp[3] = {0, sizeof(char), sizeof(char)+6*sizeof(double)};
MPI Type create struct(3, blocklen, disp, type, &Particletype);
MPI Type commit(&Particletype);
MPI Send (particle, 1000, Particletype, dest, tag, comm);
```

OUT

Informations sur les types

MPI_Get_address (void *location, MPI_Aint *address) IN location (location in caller memory)

→ Pour calculer les pas

MPI_Type_size(MPI_Datatype datatype, int *size)

address (address of location)

```
IN datatype (datatype)
OUT size (datatype size)
```

→ Retourne le nombre d'octets du datatype sans les espacements

MPI_Type_get_extent(MPI_Datatype datatype, MPI_Aint *lb, MPI_Aint *extent)

```
IN datatype (datatype you are querying)
OUT lb (lower bound of datatype)
OUT extent (extent of datatype)
```

→ Retourne la limite inf et l'étendue du datatype

A vous de jouer!