Introduction aux GPUs

Amina Guermouche

ENSEIRB-MATMÉCA

Un peu d'histoire

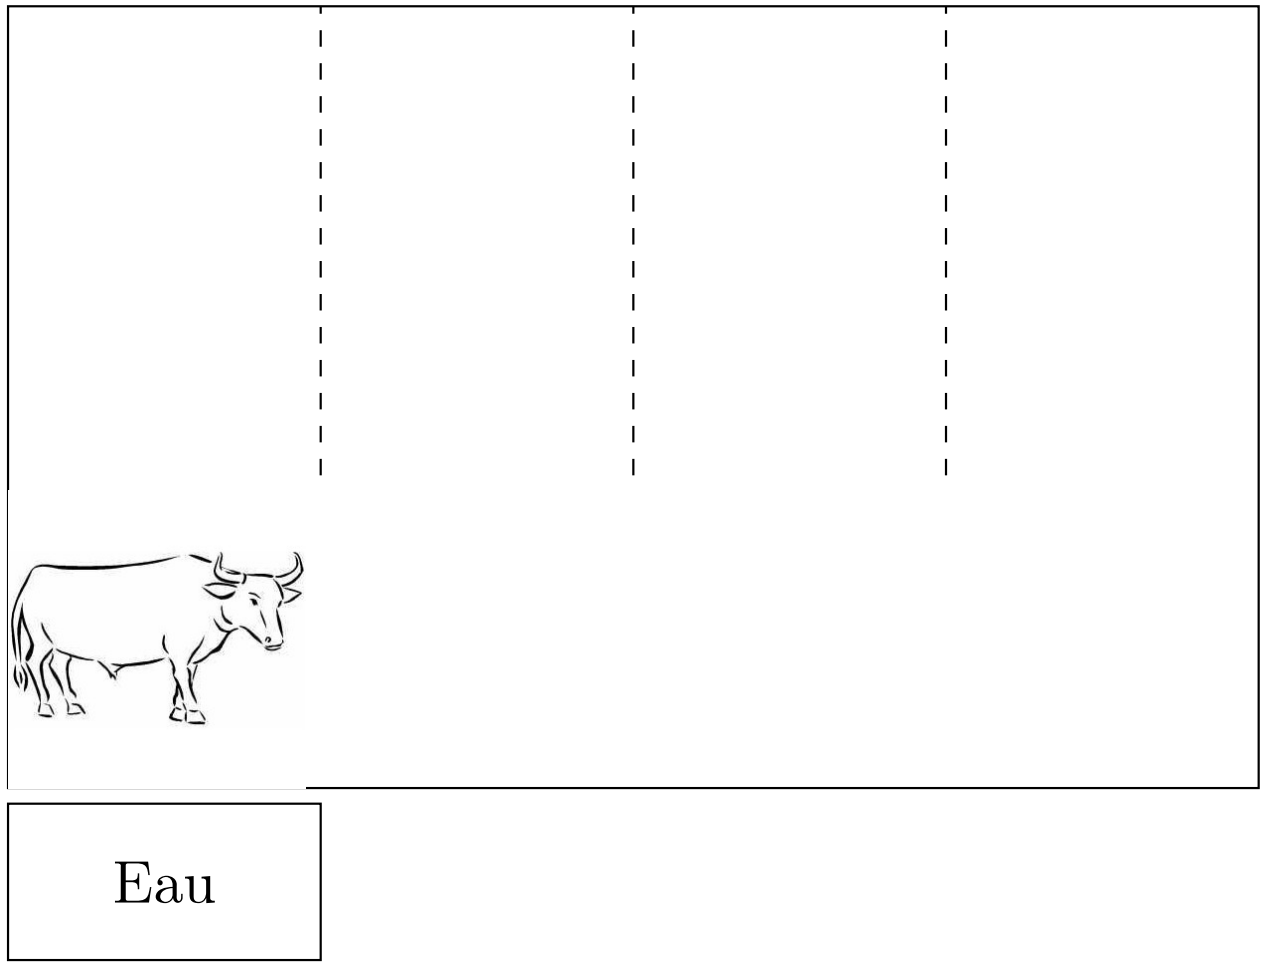

Un peu d'histoire

- Augmentation du nombre de CPU
- ☺ Plus rapide
- ☹ Plus coûteux

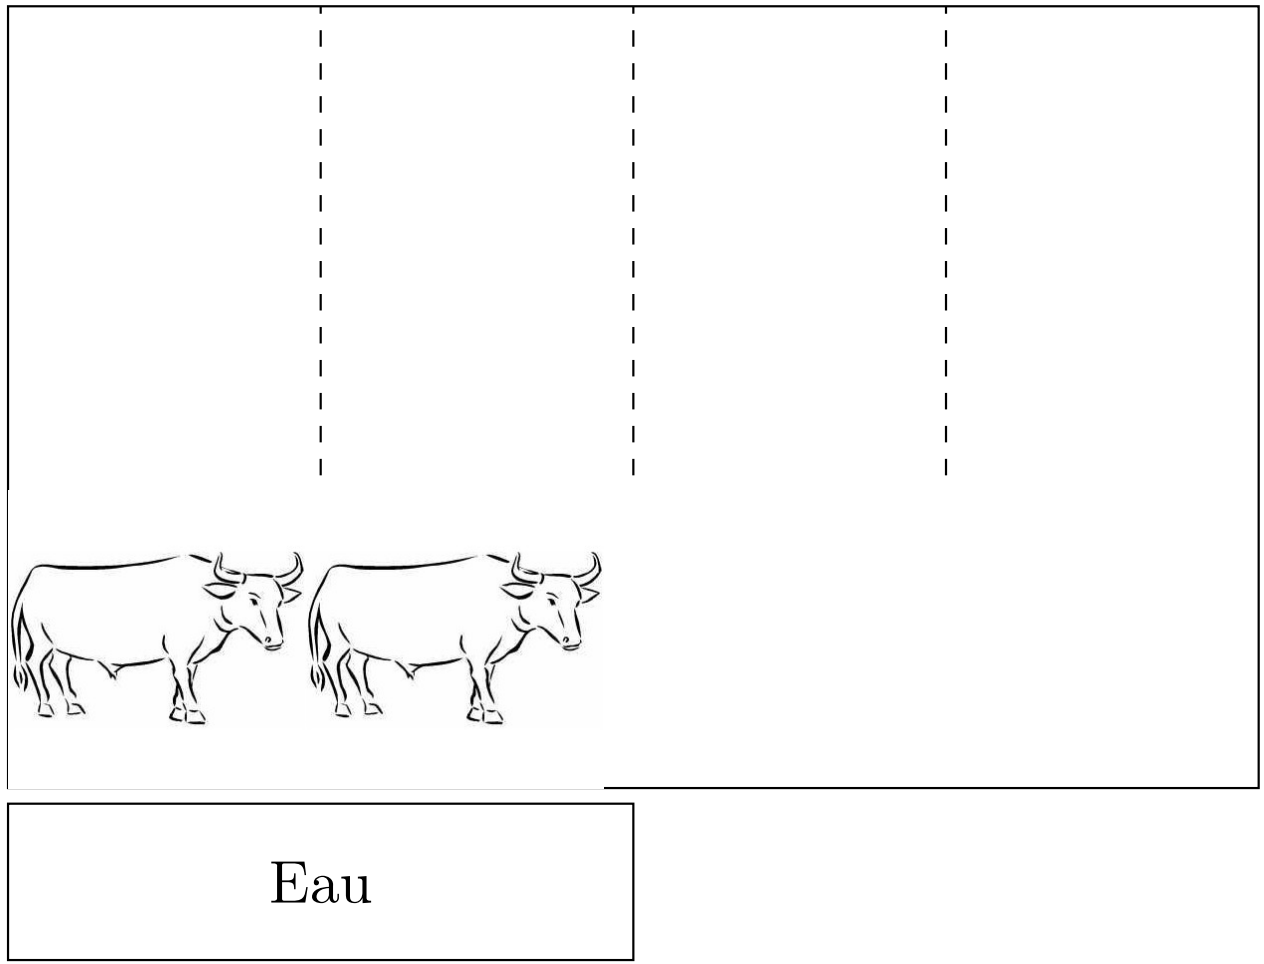

Un peu d'histoire

- Augmentation du nombre de CPU
- ☺ Plus rapide
- ☹ Plus coûteux

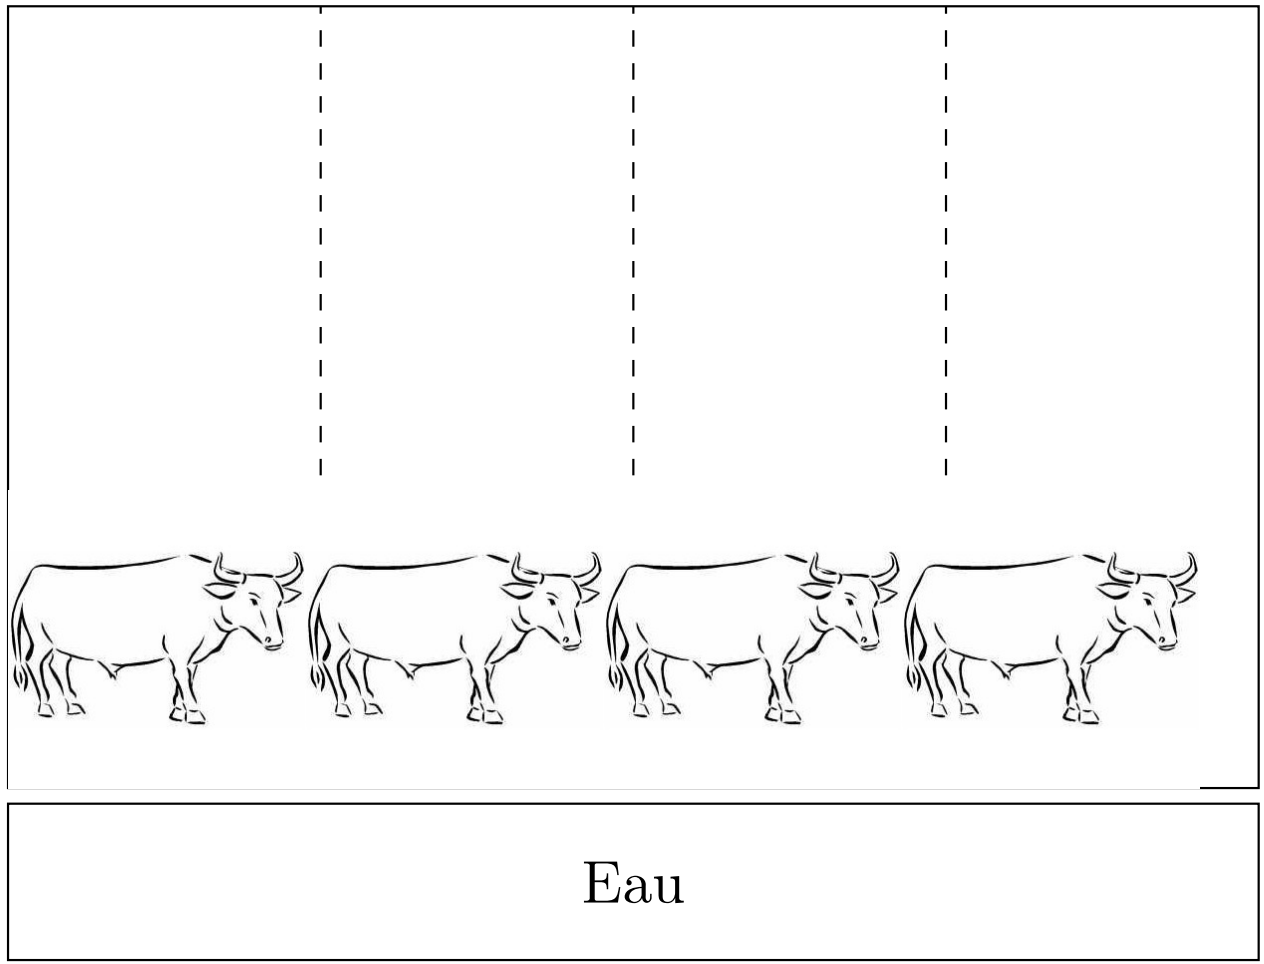

Un peu d'histoire

"If you were plowing a field, which would you rather use : Two strong oxen or 1024 chickens ?" Seymour Cray

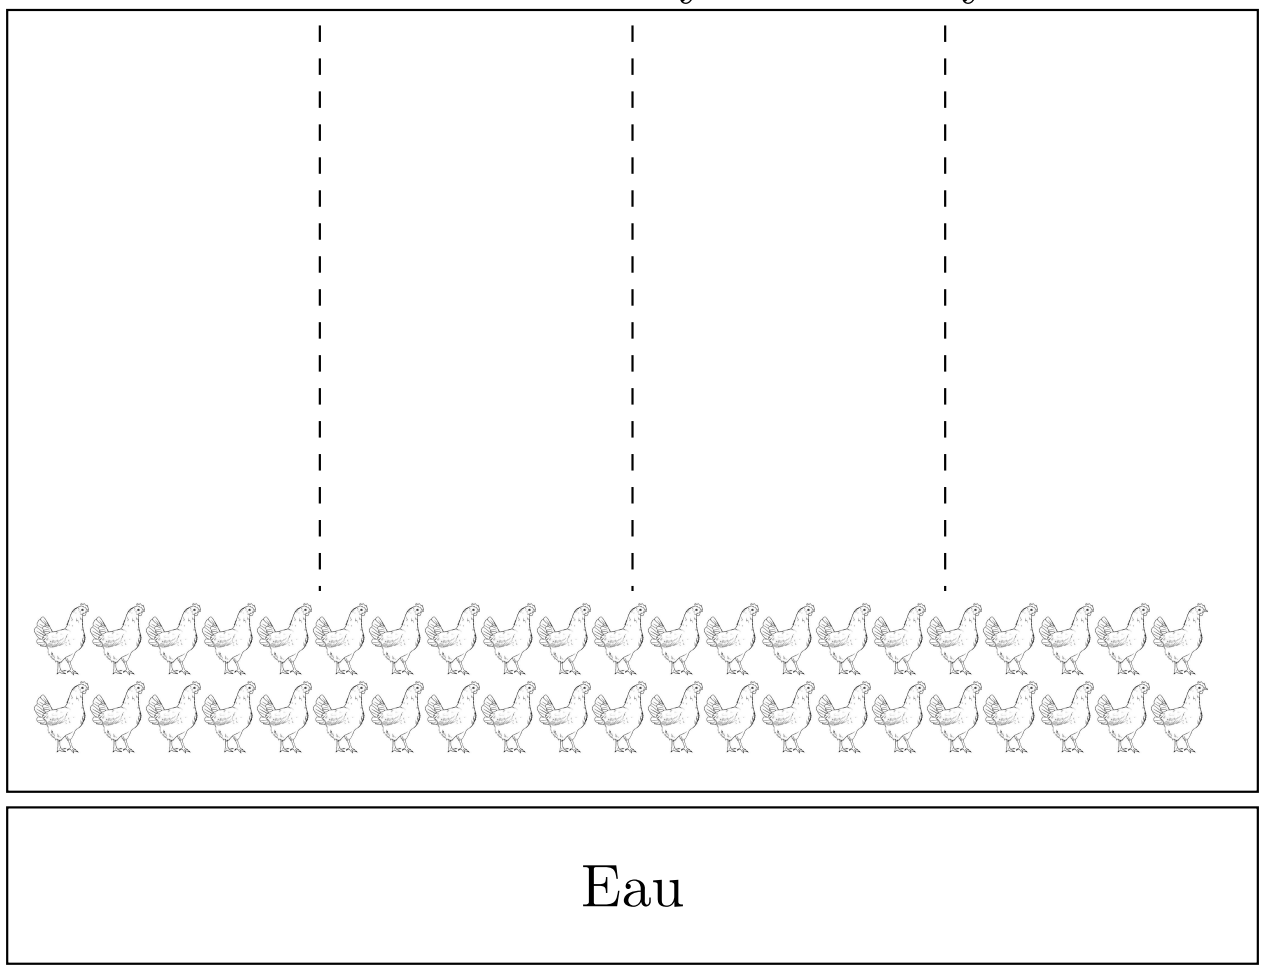

Plan

GPU VS CPU

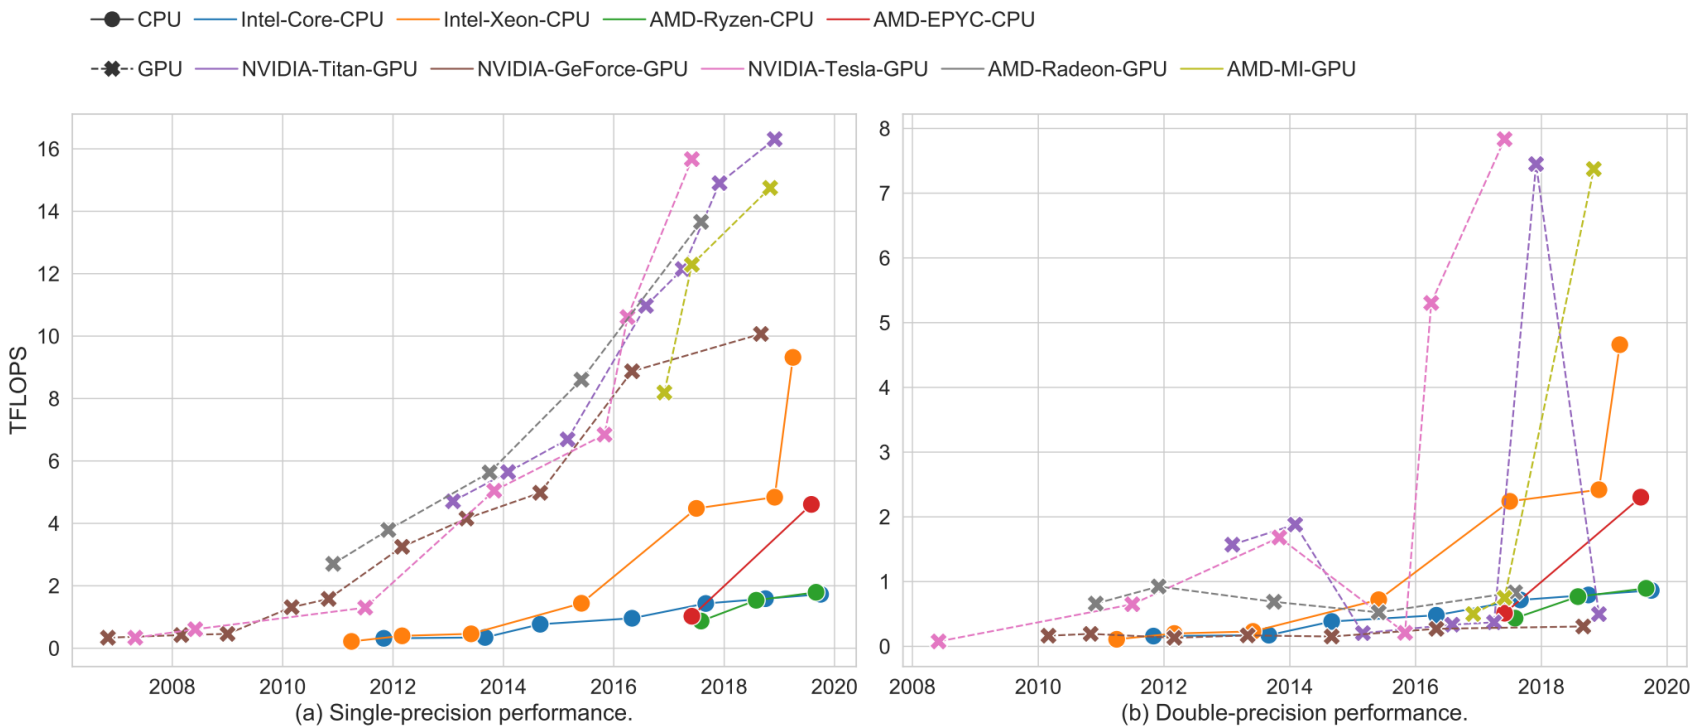

Fig. 6. Comparing single-precision and double-precision performance of CPUs and GPUs.

Référence : Summarizing CPU and GPU Design Trends with Product Data, `https://arxiv.org/abs/1911.11313`

GPU VS CPU

Intel i7 Quad-Core

$\sim$ 100 GFLOPS Peak

730 millions de transistors

4 threads + SSE vector instructions

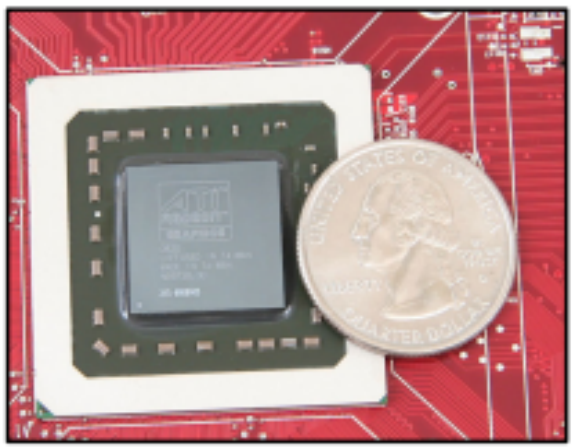

AMD Radeon HD 587

$\sim$ 2.7 TFLOPS Peak

2.2 milliards de transistors

CPU VS GPU : Démonstration

https://www.youtube.com/watch?v=-P28LKWTzrI

Pourquoi une telle différence

- Latence VS throuput
- Parallélisme de tâche VS parallélisme de données
- Multi-thread VS SIMD
- Des dizaines de threads VS des dizaines de milliers de threads

Latence et throughput

- La latence est le délai entre le moment où une opération est initiée, et le moment où ses effets deviennent détectable
  - Une voiture a une latence plus faible qu'un bus (plus rapide)

- Throughput (débit) est la quantité de travail effectué sur une durée
  - Un bus a un throughput plus élevé qu'une voiture (plus de personnes à la fois)

Latence et throughput

- Les CPU doivent minimiser la latence (négligeant le throughput ☹)
  - Un input du clavier
- Nécessité d'utiliser des caches
- Les CPUs maximisent les opérations en dehors du cache (pre-fetch, exécution out-of-order, ...)

→ Les CPU ont besoin de caches de grande taille

Latence et throughput

- Les CPU doivent minimiser la latence (négligeant le throughput ☹)
  - Un input du clavier
- Nécessité d'utiliser des caches
- Les CPUs maximisent les opérations en dehors du cache (pre-fetch, exécution out-of-order, ...)

→ Les CPU ont besoin de caches de grande taille

- Les GPU sont des processeurs à latence et throughput élevés
- Ils n'ont pas besoin de large cache
- Plus de transistors peuvent être dédiés au calcul

Pourquoi une telle différence de performance ?

- Plus de transistors sont dédiés au traitement des données au lieu de la gestion des caches
- Chip de même taille mais avec plus d'ALU, donc plus de threads pour le calcul

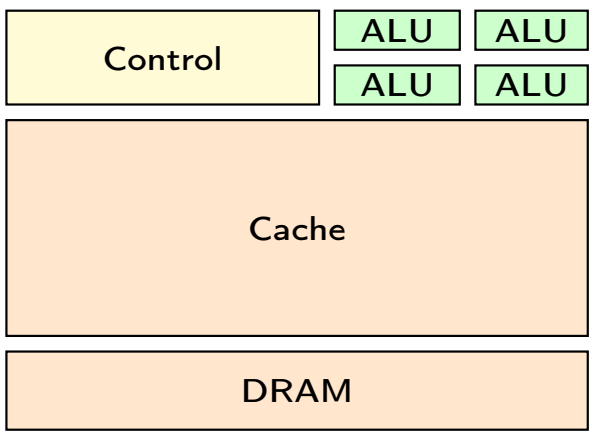

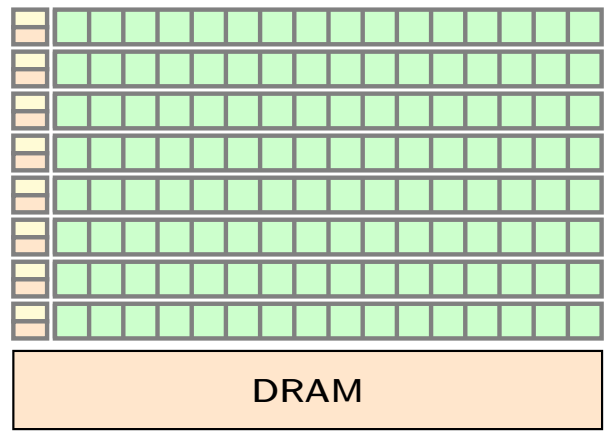

Gestion des threads sur le GPU

- **Comment faire**
  - Synchronisation entre autant de threads (comment l'éviter)
  - Ordonnancement, commutation de contexte
  - Programmation
- Les threads sur les GPUs sont :
  - Indépendants (pas de synchronisation)
  - SIMD (coût d'ordonnancement réduit)
  - Programmation par block de threads

Gestion des threads sur le GPU

- **Comment faire**
  - Synchronisation entre autant de threads (comment l'éviter)
  - Ordonnancement, commutation de contexte
  - Programmation
- Les threads sur les GPUs sont :
  - Indépendants (pas de synchronisation)
  - SIMD (coût d'ordonnancement réduit)
  - Programmation par block de threads
- Applications *data parallel*
- Applications graphiques, traitement d'images, physique, informatique, ...
- Plus il y a de données, plus les GPUs sont efficaces

Pallélisme CPU VS GPU

CPU : Parallélisme de tâches

- Exécution simultanées de plusieurs fonctions sur différents cœurs et sur des données identiques ou pas

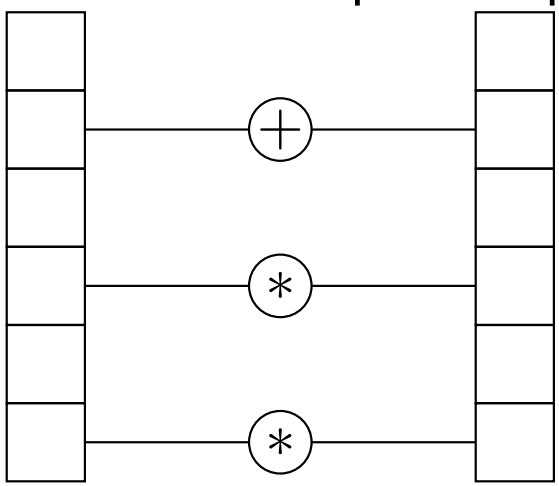

GPU : Parallélisme de données

- Exécution simultanée de la même fonction par plusieurs cœurs sur différentes données

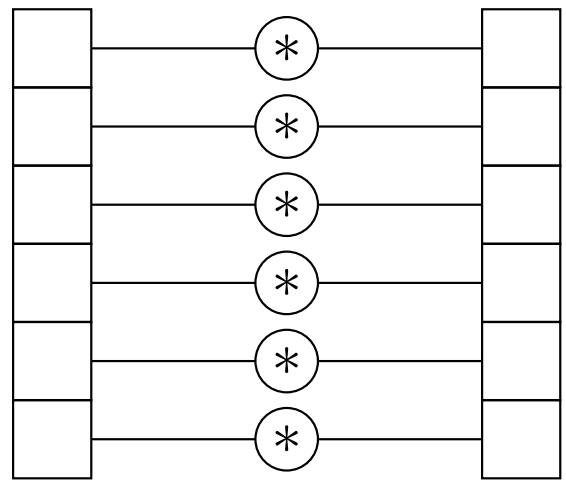

Stream processing

- L'unité fondamentale d'un GPU est le *"stream processor"*
  - Un grand ensemble de données (*"stream"*)
  - Exécuter les mêmes opérations (*"kernel"* ou *"shader"*) sur toutes les données
- Plusieurs optimisations pour améliorer le throughput
  - Mémoire et cache local on-chip pour réduire le nombre d'accès à la mémoire externe
  - Les threads sont groupés pour de meilleurs accès mémoire
    - Réduire la latence et le *"stall"*

Pourquoi les GPU ?

- Grâce aux jeux vidéos, les GPU sont :
  - très populaires
  - massivement produits (le coût est ainsi réduit)
- Les GPUs tolèrent une large latence

→ Moins de cache

→ Plus de place pour les unités de calcul

- Plus de threads
- Les GPU sont massivement parallèles :
  - Opérations (translations, rotations, ...) sur les pixels peuvent être réalisées en parallèles
  - Beaucoup d'unités de calcul
- Mémoire locale de grande taille
- Large bande passante mémoire

Plan

Vue générale du GPU Tesla P100 (P pour Pascal)

GPU P100 :

- 56 *Stream Process (SM)*
- 64 FP32 CUDA cores par SM
- 32 FP64 CUDA cores par SM
  - 1 CUDA core = 1 opération flottante par clock pour un thread
- 16GB de DRAM
- Cache L2 de 4096KB
- Connexion avec CPU via PCI express et NVLink
- Connexion entre GPU avec NVLink

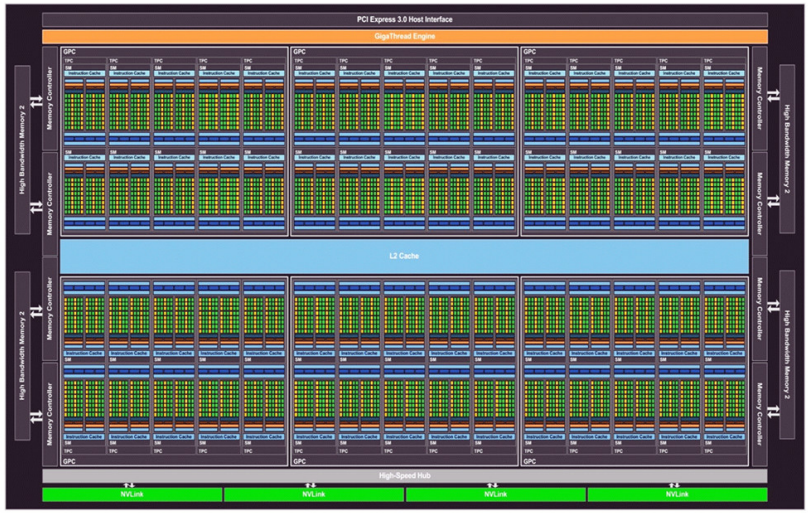

Figure – Pascal GP100 (pascal-architecture-whitepaper.pdf)

Vue détaillée du GPU Tesla P100

- 64 cœurs simple précision
- 32 cœurs double précision
- 16 unités Load/Store (LD/ST) par SM
- 16 *Special Function Units* (SFU)
  - sin, cosin, racine carrée, ...
- 64KB de mémoire partagée par SM

Référence : NVIDIA Tesla P100 white paper

Pour aller plus loin : GPU Tesla V100 (V pour Volta)

- 80 SM
- 64 cœurs simple précision par SM
- 32 cœurs double précision par SM
- Tensor cores (pour la phase d'entraînement en machine learning)

Référence : NVIDIA Tesla V100 white paper

Plan

Programmation GPU

Application d'un kernel, écrit comme un code séquentiel, à plusieurs données

- **CUDA**
  - C, C++, Fortran, Python
- OpenCL
  - Supporté par différent constructeurs (AMD et Nvidia)
  - Modèle d'exécution parallèle similaire à CUDA (mais une terminologie différente)
  - Quelques différences présentées ici : `https://people.eecs.berkeley.edu/~demmel/cs267_Spr13/Lectures/CatanzaroIntroToGPUs.pdf`
- OpenAcc

Différents constructeurs

- NVidia (CUDA)
- AMD (Hip qui fonctionne aussi pour les GPU NVidia et a une syntaxe très proche de CUDA ce qui facilite le portage du code)
- Intel Ponte Vecchio (PVC) (pas beaucoup d'informations sur comment les programmer)

Plan du cours

1. Programmation avec CUDA
2. Gestion de la mémoire
3. Mesure de la consommation d'énergie
4. Introduction à OpenACC
5. Les énoncés des TP sont disponibles ici :
   `https://cours-ag.gitlabpages.inria.fr/cisd-cuda/`

Bibliographie

- CUDA C Programming

  John Cheng, Max Grossman, Ty McKerchre, 2014
- C for CUDA by example

  Jason Senders et Edoirt Kandrot, Addison-Wesley, 2011
- Programming Massively Parallel Processors

  David B. KIRK et Wen-mei W. HWU, Morgan Kaufmann, 2010
- The CUDA handbook

  Nicholas WILT, Addison-Wesley, 2013
- `http://developer.nvidia.com/cuda/nvidia-gpucomputing-documentation`